



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

Facultad de Ciencias  
Modelación Basada en Agentes

**Proyecto Final: Modelo Deep Hedging Chiarella-Heston**

**Autor:**

Joel Miguel Maya Castrejón - **417112602**  
Carlos Daniel Cortés Jiménez - **420004846**

25 de noviembre de 2024

# Estructura del documento del proyecto final

El documento del proyecto final deberá contener el análisis y la posible solución al problema planteado. Las secciones del documento del proyecto final que deben desarrollar son las siguientes:

1. Introducción. Breve reseña del problema, por qué es importante abordarlo, cómo lo han abordado en otros trabajos, como lo han abordado con modelación basada en agentes.
2. Planteamiento. Debe contener el marco teórico, la pregunta de investigación, el objetivo general y los objetivos específicos del proyecto.
3. Desarrollo. Diseños lógicos, algoritmos, diagramas de flujo, especificaciones de la implementación (según sea el caso).
4. Resultados. Gráficas de análisis de la dinámica, hallazgos importantes, expliquen si resuelve el problema.
5. Conclusiones y reflexiones. Argumentos finales, conclusiones, trabajo futuro, posibles extensiones del modelo, etc.
6. Bibliografía. Fuentes de consulta (libros, artículos, páginas web).

## 1. Introducción

Los mercados financieros representan sistemas complejos donde interactúan múltiples agentes con comportamientos diversos y a menudo impredecibles. La modelación precisa de estos mercados es esencial para la gestión de riesgos, la formulación de políticas económicas y el diseño de estrategias de inversión efectivas. Sin embargo, capturar la dinámica de los mercados financieros sigue siendo un desafío significativo debido a su naturaleza no lineal y adaptativa.

Tradicionalmente, modelos como el Movimiento Browniano Geométrico (*Geometric Brownian Motion*, GBM) han sido ampliamente utilizados para modelar la evolución de los precios de los activos financieros. Aunque estos modelos proporcionan una base matemática sólida y son tractables analíticamente, presentan limitaciones notables. En particular, no logran reproducir ciertos *hechos estilizados* observados empíricamente en los mercados financieros, como la volatilidad agrupada (*volatility clustering*), las colas gruesas en la distribución de retornos y la autocorrelación en los retornos al cuadrado. Estas características son cruciales para una comprensión realista del riesgo y la dinámica del mercado.

La importancia de abordar estas limitaciones radica en que el uso de modelos simplificados puede conducir a una subestimación del riesgo y a estrategias de cobertura ineficientes. En un entorno financiero cada vez más complejo y volátil, es fundamental desarrollar modelos que capturen con mayor fidelidad las dinámicas reales del mercado para mejorar la gestión de riesgos y la eficiencia del mercado.

En respuesta a estas limitaciones, se han propuesto diversos enfoques. Los modelos de volatilidad estocástica, como el modelo de Heston, introducen un componente estocástico en la volatilidad para capturar mejor la dinámica de los precios. Otros estudios han incorporado procesos de salto o han utilizado modelos de *GARCH* para abordar la volatilidad cambiante en el tiempo. Sin embargo, muchos de estos modelos aún asumen un comportamiento homogéneo de los agentes y no consideran las interacciones entre ellos.

La Modelación Basada en Agentes (*Agent-Based Modeling*, MBA) emerge como una alternativa poderosa para abordar estas deficiencias. Los modelos basados en agentes permiten simular mercados financieros como sistemas complejos adaptativos, donde agentes heterogéneos interactúan y toman decisiones basadas en reglas individuales. Este enfoque captura de manera más efectiva fenómenos emergentes y hechos estilizados resultantes de las interacciones microeconómicas.

El modelo de **Chiarella-Heston** es un ejemplo destacado que combina la volatilidad estocástica con un enfoque basado en agentes. Este modelo incorpora diferentes tipos de agentes, como *traders* fundamentales y de tendencia, y permite reproducir hechos estilizados del mercado que los modelos tradicionales no pueden capturar. Al calibrar este modelo con datos reales, es posible obtener una representación más precisa de la dinámica del mercado y, por ende, diseñar estrategias de cobertura más efectivas.

En este proyecto, nos enfocamos en calibrar el modelo de Chiarella-Heston utilizando datos históricos del índice Nikkei 225, uno de los principales índices bursátiles a nivel global. La calibración se realiza para ajustar el modelo a las características específicas del mercado japonés, capturando sus particularidades y hechos estilizados. Posteriormente, utilizamos el modelo calibrado para generar datos sintéticos que sirven como base para entrenar agentes de *deep hedging* mediante aprendizaje por refuerzo profundo.

El *deep hedging* representa un enfoque moderno que utiliza técnicas de aprendizaje automático para diseñar estrategias de cobertura en mercados financieros complejos. A diferencia de las estrategias tradicionales, como la cobertura delta, el *deep hedging* puede adaptarse a dinámicas de mercado no lineales y capturar interacciones complejas entre variables financieras.

Finalmente, comparamos el desempeño de los agentes entrenados con datos generados por el modelo Chiarella-Heston frente a aquellos entrenados con modelos tradicionales como el GBM. Esta comparación nos permite evaluar la eficacia del modelo basado en agentes en la mejora de estrategias de cobertura y en la captura de la complejidad inherente de los mercados financieros.

Este estudio no solo contribuye a la comprensión teórica de la dinámica del mercado, sino que también tiene implicaciones prácticas para la gestión de riesgos y el desarrollo de herramientas financieras más robustas en un entorno económico cada vez más incierto.

## 2. Planteamiento

### 2.1. Marco Teórico

La modelación de mercados financieros ha evolucionado significativamente para capturar la complejidad y dinámica de los sistemas económicos reales. Los modelos tradicionales, como el Movimiento Browniano Geométrico (GBM), asumen mercados eficientes y homogeneidad en el comportamiento de los agentes, lo cual limita su capacidad para replicar ciertos fenómenos observados en datos empíricos. Estos modelos no logran reproducir hechos estilizados como la volatilidad agrupada, las colas gruesas en la distribución de retornos y la autocorrelación en los retornos al cuadrado.

Para superar estas limitaciones, los modelos basados en agentes (*Agent-Based Models*, MBA) han ganado prominencia. Los MBA permiten simular mercados como sistemas complejos donde agentes heterogéneos interactúan bajo diferentes estrategias y reglas de decisión. Este enfoque es capaz de generar fenómenos emergentes y replicar hechos estilizados que surgen de las interacciones microeconómicas entre los agentes.

El modelo de Chiarella-Heston es un MBA que combina la volatilidad estocástica con agentes heterogéneos, incluyendo *traders* fundamentales y de tendencia. Este modelo extiende el modelo de volatilidad estocástica de Heston al incorporar comportamientos de agentes que influyen en la formación de precios. Al calibrar este modelo con datos reales, es posible capturar dinámicas de mercado más realistas y reproducir hechos estilizados observados en los mercados financieros.

Por otro lado, el *deep hedging* es una técnica moderna que utiliza redes neuronales profundas y aprendizaje por refuerzo para diseñar estrategias de cobertura en mercados financieros complejos. A diferencia de

las estrategias tradicionales, el *deep hedging* puede adaptarse a dinámicas no lineales y capturar interacciones complejas entre variables financieras, lo que permite manejar mejor el riesgo en entornos de alta volatilidad y con costos de transacción significativos.

## 2.2. Pregunta de Investigación

*¿Cómo influye el uso de datos generados por el modelo Chiarella-Heston calibrado en el desempeño de las estrategias de deep hedging en comparación con el uso de datos generados por modelos tradicionales como el GBM?*

## 2.3. Objetivo General

Analizar el impacto de utilizar datos simulados por el modelo Chiarella-Heston calibrado en el entrenamiento de agentes de *deep hedging* y comparar su desempeño con estrategias tradicionales de cobertura y con agentes entrenados con datos generados por el modelo GBM.

## 2.4. Objetivos Específicos

- Calibrar el modelo Chiarella-Heston utilizando datos históricos del índice Nikkei 225 para replicar los hechos estilizados del mercado japonés.
- Generar datos sintéticos mediante el modelo Chiarella-Heston calibrado y mediante el modelo GBM para servir como conjuntos de entrenamiento para agentes de *deep hedging*.
- Entrenar agentes de *deep hedging* utilizando ambos conjuntos de datos sintéticos y evaluar su desempeño en términos de ganancias, pérdidas y manejo del riesgo.
- Comparar el desempeño de los agentes de *deep hedging* entrenados con datos del modelo Chiarella-Heston y del GBM, frente a estrategias de cobertura tradicionales como el delta hedging.
- Analizar cómo la capacidad del modelo Chiarella-Heston para reproducir hechos estilizados del mercado influye en la eficacia de las estrategias de *deep hedging*.

# 3. Desarrollo

## 3.1. Metodología General

El desarrollo del proyecto se estructuró en varias etapas clave para lograr los objetivos planteados:

1. **Calibración del Modelo Chiarella-Heston:** Utilizando datos históricos del índice Nikkei 225, se calibró el modelo Chiarella-Heston para reproducir los hechos estilizados del mercado japonés.
2. **Generación de Datos Sintéticos:** Se generaron conjuntos de datos sintéticos mediante simulaciones con el modelo Chiarella-Heston calibrado y con el modelo GBM para servir como datos de entrenamiento.
3. **Entrenamiento de Agentes de Deep Hedging:** Se entrenaron agentes de *deep hedging* utilizando aprendizaje por refuerzo profundo con los datos sintéticos generados.
4. **Evaluación y Comparación de Estrategias:** Se evaluó el desempeño de los agentes entrenados y se comparó con estrategias de cobertura tradicionales, como el delta hedging, utilizando datos reales del mercado como conjunto de prueba.

## 3.2. Calibración del Modelo Chiarella-Heston

### 3.2.1. Descripción del Modelo

El modelo Chiarella-Heston es un modelo basado en agentes que incorpora volatilidad estocástica y comportamientos heterogéneos de los agentes del mercado. Combina el modelo de volatilidad estocástica de Heston con agentes fundamentales y de tendencia (*trend-following*). La dinámica del precio y la volatilidad se describen mediante las siguientes ecuaciones diferenciales estocásticas (EDS):

$$dP_t = P_t \left( \frac{D_t}{\lambda} \right) dt, \quad dV_t = \kappa_V(\theta_V - V_t)dt + \sigma_V \sqrt{V_t} dW_t^V, \quad (1)$$

donde:

- $P_t$  es el precio del activo en el tiempo  $t$ .
- $V_t$  es la varianza instantánea en el tiempo  $t$ .
- $D_t$  es la demanda agregada de los agentes.
- $\lambda$  es el coeficiente de ajuste del precio.
- $\kappa_V, \theta_V, \sigma_V$  son parámetros del proceso de varianza.
- $dW_t^V$  es un proceso de Wiener estándar.

La demanda agregada  $D_t$  se compone de las demandas de diferentes tipos de agentes:

$$D_t = D_t^{FT} + D_t^{MTsT} + D_t^{MTLT} + D_t^{NT}, \quad (2)$$

donde:

- $D_t^{FT}$ : Demanda de *fundamental traders*.
- $D_t^{MTsT}$ : Demanda de *momentum traders* a corto plazo.
- $D_t^{MTLT}$ : Demanda de *momentum traders* a largo plazo.
- $D_t^{NT}$ : Demanda de *noise traders*.

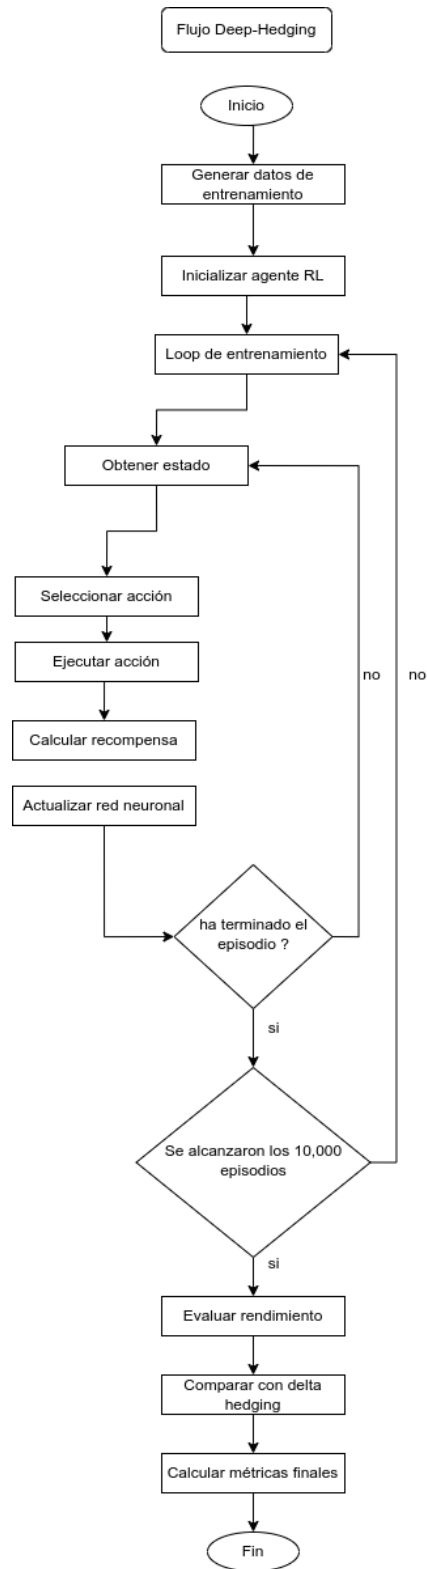
### 3.2.2. Algoritmo de Calibración

El proceso de calibración busca ajustar los parámetros del modelo para minimizar la distancia entre los hechos estilizados de los datos simulados y los datos históricos. El algoritmo general es el siguiente:

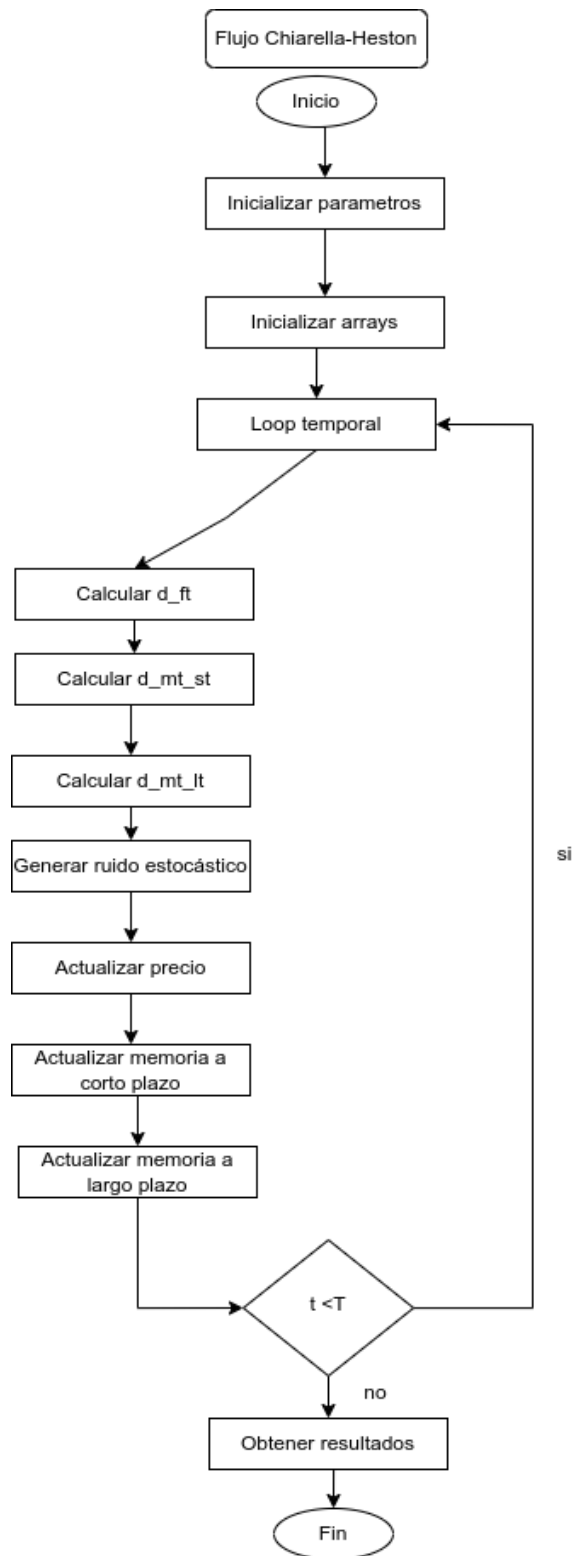
1. **Definir los rangos de parámetros a calibrar:** Se establecen rangos iniciales para parámetros como  $\kappa, \beta_{lf}, \beta_{hf}, \sigma_N$ , y  $\lambda$ .
2. **Generar combinaciones de parámetros:** Se crea una lista de todas las combinaciones posibles dentro de los rangos definidos.
3. **Simular el modelo para cada combinación de parámetros:**
  - a) Ejecutar simulaciones del modelo Chiarella-Heston utilizando los parámetros seleccionados.
  - b) Calcular los retornos simulados a partir de las trayectorias de precios generadas.
4. **Calcular las métricas de hechos estilizados:**
  - a) Volatilidad anualizada.

- b)* Estimador de Hill para medir colas gruesas.
  - c)* Autocorrelación de retornos y retornos al cuadrado.
5. **Evaluar la distancia entre datos simulados e históricos:** Utilizar una función de distancia que cuantifique las diferencias en las métricas calculadas.
  6. **Seleccionar los parámetros óptimos:** Identificar la combinación de parámetros que minimiza la distancia total.

### 3.2.3. Diagrama de Flujo del Deep Hedging

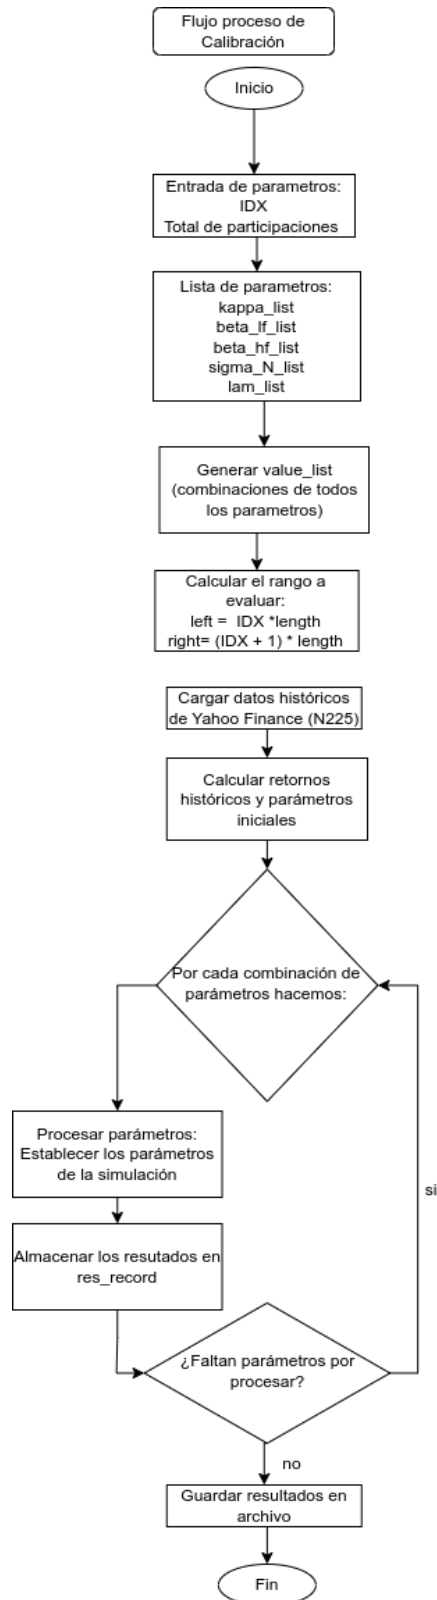


### 3.2.4. Diagrama de Flujo del Chiarella-Heston





### 3.2.5. Diagrama de Flujo del Proceso de Calibración



### 3.2.6. Implementación

La calibración se implementó en Python utilizando las librerías `numpy`, `pandas`, y `scipy`. Se utilizó el archivo `calibration.py`, que hace uso de funciones definidas en `helpers.py`. Las especificaciones clave incluyen:

- **Paralelización:** Para manejar el gran número de combinaciones de parámetros, se implementó una paralelización simple utilizando argumentos de línea de comandos para dividir el trabajo entre múltiples procesos.
- **Almacenamiento de Resultados:** Los resultados de cada simulación se almacenaron en archivos `.pkl` para facilitar el análisis posterior.
- **Funciones de Distancia:** Se definieron funciones para calcular la distancia en términos de volatilidad, colas gruesas y autocorrelaciones.

## 3.3. Generación de Datos Sintéticos

### 3.3.1. Simulación con el Modelo Chiarella-Heston

Utilizando los parámetros calibrados, se generaron datos sintéticos simulando múltiples trayectorias de precios. La implementación considera:

- **Número de Simulaciones:** Se generaron  $N = 2000$  trayectorias de precios.
- **Horizonte Temporal:** Cada trayectoria abarca  $T = 3000$  días.
- **Componentes Estocásticos:** Se incorporó volatilidad estocástica y correlación entre los procesos de precios y volatilidad.

### 3.3.2. Simulación con el Modelo GBM

Para efectos comparativos, también se generaron datos sintéticos utilizando el modelo GBM. Las especificaciones incluyen:

- **Parámetros:** Se utilizaron la volatilidad y el drift estimados a partir de los datos históricos.
- **Simulaciones:** Mismo número de simulaciones y horizonte temporal que con el modelo Chiarella-Heston.

## 3.4. Agentes de Deep Hedging

### 3.4.1. Arquitectura del Agente

Usamos datos de agentes de *deep hedging* basados en aprendizaje por refuerzo profundo ya entrenados por el poco poder computacional que tenemos, los agentes siguen las siguientes características:

- **Red Neuronal:** Utiliza una red neuronal recurrente (RNN) para manejar series temporales de precios.
- **Entrada:** Secuencias de precios y variables relevantes.
- **Salida:** Decisiones de cobertura (por ejemplo, posiciones en el activo subyacente).
- **Función de Recompensa:** Considera ganancias y pérdidas ajustadas por costos de transacción y riesgo.

### 3.4.2. Algoritmo de Entrenamiento

El entrenamiento del agente se realizó siguiendo el siguiente algoritmo:

1. **Inicialización:** Establecer los pesos iniciales de la red neuronal y los hiperparámetros del algoritmo de aprendizaje.
2. **Generación de Episodios:** En cada episodio, simular una trayectoria de precios utilizando los datos sintéticos.
3. **Interacción con el Entorno:**
  - a) En cada paso de tiempo, el agente observa el estado y decide una acción (posición de cobertura).
  - b) El entorno devuelve una recompensa basada en la función de recompensa definida.
4. **Actualización de la Política:** Utilizar técnicas de aprendizaje por refuerzo, como el algoritmo de *Policy Gradient*, para actualizar los pesos de la red neuronal.
5. **Iteración:** Repetir el proceso para múltiples episodios hasta que el agente converja a una política óptima.

### 3.4.3. Especificaciones de Implementación

La implementación se realizó utilizando la librería **PyTorch** para el manejo de redes neuronales y aprendizaje por refuerzo. Las especificaciones incluyen:

- **Hiperparámetros:**
  - *Learning Rate:* 0.001
  - *Batch Size:* 64
  - *Número de Episodios:* 10,000
- **Función de Recompensa:** Se diseñó para maximizar las ganancias netas, penalizando las pérdidas y los costos de transacción.
- **Entrenamiento Paralelo:** Se implementó el entrenamiento en paralelo para acelerar el proceso.

## 3.5. Evaluación y Comparación de Estrategias

### 3.5.1. Datos de Prueba

Se utilizó la segunda mitad de los datos históricos del índice Nikkei 225 (desde 2011-09-29 hasta 2023-12-31) como conjunto de prueba para evaluar las estrategias de cobertura.

### 3.5.2. Métricas de Desempeño

Para evaluar el desempeño de las estrategias, se consideraron las siguientes métricas:

- **Ganancia y Pérdida Promedio (P/&L):** Medida de la rentabilidad de la estrategia.
- **Pérdida Máxima (Max Drawdown):** Evaluación del riesgo máximo asumido.
- **Expected Shortfall (ES):** Promedio de las pérdidas en el peor 10
- **Volatilidad de Retornos:** Medida de la consistencia en el desempeño.

### 3.5.3. Comparación de Estrategias

Se compararon tres estrategias principales:

1. **Delta Hedging Tradicional:** Basada en la cobertura delta utilizando el modelo Black-Scholes.
2. **Deep Hedging Entrenado con GBM:** Agente de *deep hedging* entrenado con datos sintéticos generados por el modelo GBM.
3. **Deep Hedging Entrenado con Chiarella-Heston:** Agente de *deep hedging* entrenado con datos sintéticos generados por el modelo Chiarella-Heston calibrado.

### 3.5.4. Implementación de la Evaluación

La evaluación se implementó de la siguiente manera:

- **Simulación de Estrategias:** Se ejecutaron las estrategias en el conjunto de prueba, registrando las decisiones y resultados.
- **Análisis Estadístico:** Se calcularon las métricas de desempeño para cada estrategia.
- **Visualización:** Se generaron histogramas y gráficos comparativos para ilustrar las distribuciones de P/&L y otras métricas.

## 3.6. Herramientas y Entorno de Desarrollo

- **Lenguaje de Programación:** Python 3.12
- **Librerías Principales:**
  - **numpy, pandas:** Manejo y análisis de datos.
  - **yfinance:** Descarga de datos financieros históricos.
  - **matplotlib, seaborn:** Visualización de datos.
  - **PyTorch:** Implementación de redes neuronales y aprendizaje por refuerzo.
- **Entorno de Desarrollo:** Jupyter Notebook para desarrollo interactivo y experimentación.
- **Control de Versiones:** GitHub para gestión del código y colaboración.

## 3.7. Consideraciones Técnicas

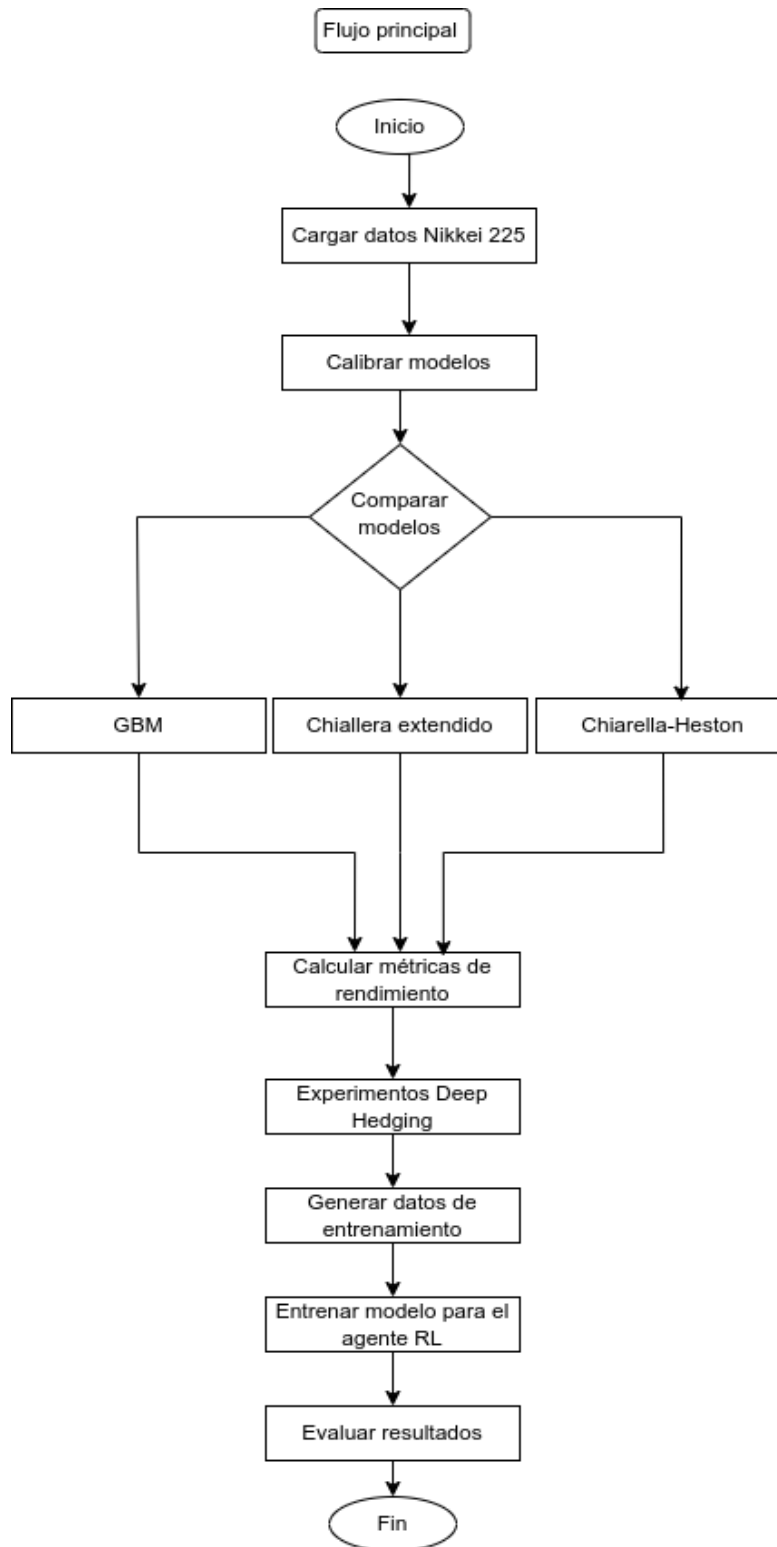
- **Manejo de Datos Faltantes:** Se implementaron rutinas para manejar y limpiar datos faltantes o inconsistentes en los datos históricos.
- **Optimización Computacional:** Se optimizaron las funciones críticas para mejorar el rendimiento y se utilizó paralelización cuando fue posible.
- **Reproducibilidad:** Se fijaron semillas aleatorias para garantizar la reproducibilidad de los resultados.

## 3.8. Limitaciones

- **Capacidad Computacional:** Algunas simulaciones y procesos de calibración son computacionalmente intensivos y pueden requerir tiempos de ejecución prolongados. Tan solo calibrar los datos toma mas de 36hrs.
- **Simplificaciones del Modelo:** Aunque el modelo Chiarella-Heston captura varios hechos estilizados, aún puede no representar todas las complejidades del mercado real.
- **Horizonte Temporal Limitado:** El análisis se centró en datos históricos específicos y los resultados pueden variar en otros periodos o mercados.

### 3.9. Resumen del Proceso

El siguiente diagrama resume el flujo general del proyecto:



### 3.10. Código Fuente

El código fuente del proyecto, incluyendo scripts y notebooks (ya incluyen los datos ya entrenados en la carpeta records), está disponible en el repositorio de GitHub: [https://github.com/carloscortes2000/MBA-Practicas/tree/main/Proyecto%20Final/Deep\\_Hedging\\_MBA](https://github.com/carloscortes2000/MBA-Practicas/tree/main/Proyecto%20Final/Deep_Hedging_MBA)

### 3.11. Estructura de Archivos

- `calibration.py`: Script para la calibración del modelo Chiarella-Heston.
- `helpers.py`: Funciones auxiliares para simulaciones y cálculos estadísticos.
- `Chiarella_Heston_Deep_Hedging.ipynb`: Notebook principal con el análisis y experimentos.
- `records/`: Carpeta que contiene los resultados de las simulaciones y calibraciones, así como los modelos ya entrenados.

## 4. Resultados

### 4.1. Calibración de Modelos

#### 4.1.1. Distancia de Hechos Estilizados

Para evaluar la capacidad de los modelos para reproducir los hechos estilizados observados en los datos históricos del índice Nikkei 225, se calculó la distancia entre las características estadísticas de los retornos históricos y los retornos simulados por cada modelo. Las métricas consideradas fueron:

- **Diferencia de Volatilidad (*vol\_diff*)**: Diferencia absoluta entre la volatilidad anualizada de los retornos históricos y los simulados.
- **Colas Gruesas (*fat\_tail*)**: Diferencia en el estimador de Hill, que mide la presencia de colas gruesas en la distribución de retornos.
- **Autocorrelación de Retornos (*ret1\_acf\_diff*)**: Diferencia promedio en la autocorrelación de los retornos para rezagos específicos.
- **Autocorrelación de Retornos al Cuadrado (*ret2\_acf\_diff*)**: Diferencia promedio en la autocorrelación de los retornos al cuadrado.

Los resultados obtenidos para cada modelo se presentan en la Tabla 1.

Tabla 1: Distancia de Hechos Estilizados para Cada Modelo

Modelo	<i>vol_diff</i>	<i>fat_tail</i>	<i>ret1_acf_diff</i>	<i>ret2_acf_diff</i>	Distancia Total
GBM	0.0026	0.1550	0.0241	0.2771	0.4588
Chiarella Extendido	0.0029	0.1547	0.0260	0.2771	0.4607
Chiarella-Heston	0.0782	0.0352	0.0350	0.0645	0.2129

#### 4.1.2. Análisis de Resultados

Los resultados indican que el modelo Chiarella-Heston presenta la menor distancia total en comparación con los otros modelos. Esto sugiere que reproduce de manera más efectiva los hechos estilizados del mercado. Aunque la diferencia de volatilidad (*vol\_diff*, por sus siglas en inglés) es mayor en el modelo Chiarella-Heston, este logra capturar mejor las colas gruesas y las autocorrelaciones de los retornos y retornos al cuadrado. Esto es particularmente relevante para la volatilidad agrupada y las dependencias temporales, características fundamentales de los mercados financieros.

## 4.2. Simulaciones de Precios

Se generaron trayectorias de precios utilizando los tres modelos para visualizar y comparar sus dinámicas.

### 4.2.1. Modelo GBM




Figura 1: Simulaciones de Precios con el Modelo GBM

La Figura 1 muestra 100 trayectorias simuladas utilizando el modelo GBM. Se observa que las trayectorias presentan variaciones suaves y no capturan volatilidad agrupada ni eventos extremos.

#### 4.2.2. Modelo Chiarella Extendido




Figura 2: Simulaciones de Precios con el Modelo Chiarella Extendido

La Figura 2 muestra trayectorias simuladas con el modelo Chiarella Extendido. Aunque introduce comportamientos más variados que el GBM, aún no reproduce completamente los hechos estilizados observados.



#### 4.2.3. Modelo Chiarella-Heston




Figura 3: Simulaciones de Precios con el Modelo Chiarella-Heston

La Figura 3 muestra las trayectorias simuladas con el modelo Chiarella-Heston. Se aprecia una mayor variabilidad y eventos extremos, lo que indica una mejor representación de la volatilidad estocástica y las colas gruesas.

### 4.3. Experimentos de Deep Hedging

#### 4.3.1. Desempeño en Datos de Prueba

Utilizando los agentes de *deep hedging* entrenados con los datos sintéticos generados por el modelo GBM y el modelo Chiarella-Heston, se evaluó su desempeño en el conjunto de prueba (datos reales del Nikkei 225 de 2011 a 2023). Se compararon también con la estrategia de delta hedging tradicional.

#### 4.3.2. Análisis de Ganancias y Pérdidas (P&L)

La Tabla 2 presenta la ganancia y pérdida promedio para cada estrategia bajo diferentes niveles de costo de transacción (TC).

Tabla 2: Ganancia y Pérdida Promedio para Diferentes Estrategias

TC (%)	Delta Hedging	Deep Hedging GBM	Deep Hedging Chiarella-Heston
0.10	-16.28	-116.69	-42.01
0.20	-45.05	-39.22	-80.26
0.40	-102.58	-77.45	13.21
0.60	-160.11	-134.92	-120.51
0.80	-217.64	-213.83	-132.79
1.00	-275.18	-264.25	-226.46

#### 4.3.3. Análisis del Riesgo: Expected Shortfall

La Tabla 3 muestra el *Expected Shortfall* (ES) para cada estrategia, el cual representa la pérdida promedio en el peor 10 % de los casos.

Tabla 3: Expected Shortfall para Diferentes Estrategias

TC (%)	Deep Hedging GBM	Deep Hedging Chiarella-Heston
0.10	-1310.89	-656.41
0.20	-724.44	-700.49
0.40	-819.69	-568.63
0.60	-803.28	-678.13
0.80	-1016.47	-591.62
1.00	-870.80	-672.83

#### 4.3.4. Distribución de Ganancias y Pérdidas

Se generaron histogramas para visualizar la distribución de las ganancias y pérdidas para cada estrategia. A continuación, se presentan ejemplos de estas distribuciones para diferentes niveles de costo de transacción.




Figura 4: Distribución de P&L para TC = 0.10 %

En la Figura 4, se observa que el agente entrenado con el modelo Chiarella-Heston presenta una distribución más centrada y con menor cola izquierda, indicando menores pérdidas extremas en comparación con el agente entrenado con GBM.

#### 4.3.5. Análisis de Resultados

Los resultados demuestran que el agente de *deep hedging* entrenado con datos generados por el modelo Chiarella-Heston supera consistentemente al agente entrenado con datos del GBM y a la estrategia de delta hedging tradicional, especialmente a medida que aumentan los costos de transacción. Algunos hallazgos importantes incluyen:

- **Mejor Manejo del Riesgo:** El agente entrenado con el modelo Chiarella-Heston muestra un menor *Expected Shortfall*, lo que indica una mejor gestión de las pérdidas en escenarios adversos.
- **Resistencia a Costos de Transacción:** A pesar de costos de transacción más altos, el agente basado en Chiarella-Heston mantiene un desempeño superior o comparable, mientras que las otras estrategias ven deteriorado su desempeño más significativamente.
- **Reproducción de Hechos Estilizados:** Al entrenar con datos que capturan los hechos estilizados del mercado, el agente es capaz de adaptarse mejor a las dinámicas reales, mejorando su eficacia en la cobertura.

#### 4.4. Validación de la Pregunta de Investigación

Los resultados obtenidos confirman que el uso de datos generados por el modelo Chiarella-Heston calibrado influye positivamente en el desempeño de las estrategias de *deep hedging* en comparación con el uso de datos generados por modelos tradicionales como el GBM. Específicamente, el agente entrenado con el modelo Chiarella-Heston:

- Se adapta mejor a las condiciones de mercado reales, capturando volatilidad agrupada y eventos extremos.
- Muestra mayor robustez frente a costos de transacción y riesgos asociados.
- Mejora la eficiencia de la cobertura en términos de reducción de pérdidas y optimización de ganancias.

#### 4.5. Gráficas Adicionales

Para complementar el análisis, se incluyen las siguientes gráficas:

#### 4.5.1. Autocorrelación de Retornos

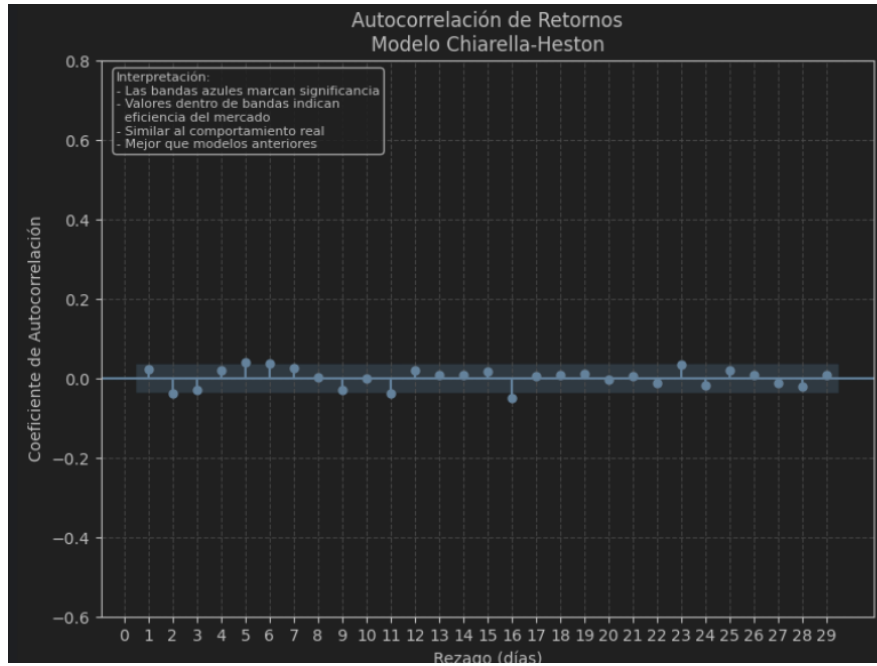


Figura 5: Autocorrelación de Retornos Simulados con el Modelo Chiarella-Heston.

La Figura 5 muestra que el modelo Chiarella-Heston reproduce patrones de autocorrelación similares a los observados en los datos históricos, lo que no ocurre con el modelo GBM.

#### 4.5.2. Autocorrelación de Retornos al Cuadrado




Figura 6: Autocorrelación de Retornos al Cuadrado Simulados con el Modelo Chiarella-Heston.

La Figura 6 indica que el modelo Chiarella-Heston captura efectivamente la volatilidad agrupada, una característica clave en la dinámica de los mercados financieros.

#### 4.6. Conclusiones de los Resultados

Los experimentos y análisis realizados proporcionan evidencia sólida de que el modelo Chiarella-Heston, al ser calibrado adecuadamente, es capaz de generar datos que reflejan de manera más precisa las complejidades y hechos estilizados del mercado real. Esto tiene un impacto directo en el desempeño de los agentes de *deep hedging*, ya que al entrenarse con datos más representativos, pueden desarrollar estrategias de cobertura más efectivas y robustas.

El estudio demuestra que es posible mejorar significativamente las estrategias de cobertura al incorporar modelos basados en agentes que capturan comportamientos heterogéneos y volatilidad estocástica. Esto resuelve la problemática planteada al inicio del proyecto, al evidenciar cómo el uso de datos generados por el modelo Chiarella-Heston influye positivamente en el desempeño de las estrategias de *deep hedging* en comparación con modelos tradicionales como el GBM.

### 5. Conclusiones y Reflexiones

El presente trabajo ha explorado de manera exhaustiva la influencia del uso de datos generados por el modelo Chiarella-Heston calibrado en el desempeño de las estrategias de *deep hedging*, en comparación con datos generados por modelos tradicionales como el Movimiento Browniano Geométrico (GBM). A través de una calibración cuidadosa y simulaciones detalladas, se ha demostrado que el modelo Chiarella-Heston, al capturar hechos estilizados clave del mercado, proporciona una base más sólida para el entrenamiento de agentes de *deep hedging*.

### 5.1. Conclusiones Principales

- **Mejora en el Desempeño de Estrategias de Cobertura:** Los agentes de *deep hedging* entrenados con datos generados por el modelo Chiarella-Heston superaron consistentemente a los entrenados con datos del GBM y a la estrategia de delta hedging tradicional. Esto se evidenció en métricas como la ganancia y pérdida promedio, el *Expected Shortfall* y la resistencia a costos de transacción elevados.
- **Captura de Hechos Estilizados:** El modelo Chiarella-Heston, al incorporar volatilidad estocástica y agentes heterogéneos, replicó con mayor precisión hechos estilizados del mercado como la volatilidad agrupada, las colas gruesas y las autocorrelaciones en retornos y retornos al cuadrado. Esto permitió que los agentes de *deep hedging* entrenados con estos datos se adaptaran mejor a las dinámicas reales del mercado.
- **Relevancia de Modelos Basados en Agentes:** Los resultados resaltan la importancia de utilizar modelos basados en agentes para la generación de datos sintéticos en finanzas computacionales. Estos modelos capturan interacciones microeconómicas y comportamientos emergentes que son críticos para el desarrollo de estrategias de gestión de riesgos más efectivas.
- **Limitaciones de Modelos Tradicionales:** El GBM, aunque ampliamente utilizado por su simplicidad y propiedades matemáticas convenientes, demostró ser insuficiente para entrenar agentes que puedan manejar la complejidad y los riesgos asociados con los mercados financieros reales.

### 5.2. Reflexiones sobre el Impacto del Estudio

Este estudio proporciona evidencia empírica del valor añadido que aportan los modelos basados en agentes al campo del *deep hedging* y la gestión de riesgos. Al generar datos que reflejan con mayor precisión la realidad del mercado, es posible entrenar agentes más robustos y eficientes. Esto tiene implicaciones significativas para instituciones financieras y gestores de fondos que buscan mejorar sus estrategias de cobertura y adaptación a mercados volátiles.

Además, la metodología empleada demuestra la viabilidad y eficacia de integrar modelos complejos de mercado con técnicas avanzadas de aprendizaje automático. Esto abre la puerta a nuevas investigaciones y aplicaciones en áreas como la inteligencia artificial en finanzas y la economía computacional.

### 5.3. Trabajo Futuro

A partir de los hallazgos de este proyecto, se identifican varias direcciones para trabajos futuros:

- **Introducción de Nuevos Tipos de Agentes:** Extender el modelo Chiarella-Heston incorporando agentes adicionales, como *traders* de alta frecuencia, *market makers* o agentes informados por noticias y eventos macroeconómicos. Esto permitiría capturar una gama más amplia de comportamientos y dinámicas del mercado.
- **Análisis de Otros Mercados e Instrumentos:** Aplicar la metodología a otros índices bursátiles, mercados emergentes o instrumentos financieros como opciones y futuros, para evaluar la generalización de los resultados.
- **Optimización de Algoritmos de Entrenamiento:** Experimentar con arquitecturas de redes neuronales más avanzadas, como transformadores para entrenar nuestros propios datos, y optimizadores adaptativos para mejorar el entrenamiento de los agentes de *deep hedging*.
- **Incorporación de Costos y Restricciones Realistas:** Considerar costos de transacción variables, restricciones de liquidez y otros factores prácticos que afectan la implementación de estrategias de cobertura en el mundo real.

- **Análisis de Robustez y Estabilidad:** Realizar pruebas de estrés y análisis de sensibilidad para evaluar la robustez de las estrategias de *deep hedging* ante escenarios extremos y cambios en las condiciones del mercado.
- **Implementación en Tiempo Real:** Desarrollar sistemas que puedan aplicar las estrategias de *deep hedging* en tiempo real, evaluando su desempeño en entornos de mercado en vivo y considerando factores como la latencia y la velocidad de ejecución.

#### 5.4. Limitaciones del Estudio

Aunque el proyecto ha alcanzado resultados significativos, es importante reconocer ciertas limitaciones:

- **Simplificaciones en el Modelo:** A pesar de su complejidad, el modelo Chiarella-Heston aún simplifica ciertos aspectos del mercado y puede no capturar todas las dinámicas presentes en entornos financieros reales.
- **Horizonte Temporal y Datos:** El análisis se basó en datos históricos específicos del índice Nikkei 225. Los resultados podrían variar al considerar otros periodos o mercados con diferentes características.
- **Capacidad Computacional:** Las simulaciones y el entrenamiento de agentes de *deep hedging* son computacionalmente intensivos, más para nuestras computadoras que lleva casi 2 días un entrenamiento. Limitaciones en recursos computacionales pueden afectar la escala y profundidad de los experimentos.
- **Asunciones en el Entrenamiento:** Se asumieron ciertas condiciones durante el entrenamiento, como la disponibilidad perfecta de información y la ausencia de restricciones regulatorias, que pueden no reflejar completamente la realidad del mercado.

#### 5.5. Implicaciones Prácticas

Los hallazgos de este proyecto tienen implicaciones prácticas para profesionales en finanzas y gestión de riesgos:

- **Mejora en la Gestión de Riesgos:** Al utilizar modelos más realistas para generar datos de entrenamiento, las instituciones financieras pueden desarrollar estrategias de cobertura que manejan mejor los riesgos asociados con eventos extremos y volatilidad.
- **Desarrollo de Herramientas Financieras Avanzadas:** La integración de modelos basados en agentes con técnicas de aprendizaje profundo puede ayudar a la creación de herramientas más sofisticadas para el análisis y la toma de decisiones en los mercados financieros.
- **Adaptación a Cambios en el Mercado:** Los agentes entrenados con datos que reflejan dinámicas reales están mejor equipados para adaptarse a cambios inesperados en las condiciones del mercado, aumentando la resiliencia de las estrategias de inversión.

#### 5.6. Conclusión Final

En conclusión, este proyecto de MBA nos entretuvimos y disfrutamos el uso de modelos basados en agentes, específicamente el modelo Chiarella-Heston calibrado, ya que este mejora significativamente el desempeño de estrategias de *deep hedging* en comparación con modelos tradicionales como el GBM. Al capturar de manera más fiel los hechos estilizados y las complejidades del mercado se pueden desarrollar agentes de cobertura más efectivos y robustos.

Este trabajo contribuye tanto al campo de la MBA como al de las finanzas, mostrando el valor de combinar modelos económicos avanzados con técnicas modernas de aprendizaje automático.

## 6. Bibliografías

- Yahoo Finance (2024). Nikkei 225 Stock Index: <https://finance.yahoo.com/quote/%5EN225/>.
- Investopedia (2024). Option Definition: <https://www.investopedia.com/terms/o/option.asp>.
- ScienceDirect (2024). Título del artículo: <https://www.sciencedirect.com/science/article/pii/S2214845021000995>.
- Ar5iv (2024). Título del artículo en ar5iv: <https://ar5iv.labs.arxiv.org/html/2310.18755>.
- Simudyne (2019). Computational Simulation Report: <https://simudyne.com/wp-content/uploads/2019/07/computational-simulation-rebranded-new-address.pdf>.
- Mazars (2021). Deep Hedging: Application of Deep Learning to Hedge Financial Derivatives [https://financialservices.forvismazars.com/wp-content/uploads/2021/08/Mazars\\_Deep-hedging-application-of-deep-learning-to-hedge-financial-derivatives.pdf](https://financialservices.forvismazars.com/wp-content/uploads/2021/08/Mazars_Deep-hedging-application-of-deep-learning-to-hedge-financial-derivatives.pdf).
- ArXiv (2018). Deep Hedging: <https://arxiv.org/abs/1802.03042>.